Dicionário de Dados – ETL e DW do Censo Escolar

Oct 20, 2026 · @lalmo

Banco `db_educacional`, esquemas `staging` e `dw`, carregado com os microdados do Censo Escolar 2024 e 2025 (INEP). Os nomes das colunas de origem são os do dicionário oficial do INEP (Anexo I dos microdados).

1. Mapeamento origem → staging → DW

Dos 426 campos do CSV de 2024 (e dos 290 + 263 de 2025), 22 são lidos. Todos entram na staging com o mesmo nome, em minúsculas.

Coluna INEP	Descrição (INEP)	Arquivo de origem em 2025	Destino no DW	Transformação
NU_ANO_CENSO	Ano do Censo	Escola	– (validação)	V08: deve ser igual ao ano da carga
CO_ENTIDADE	Código da escola	Escola	`dim_escola.co_entidade`	Conversão para BIGINT; V01
NO_ENTIDADE	Nome da escola	Escola	`dim_escola.no_entidade`	RT01, RT02, RT03; V02
TP_DEPENDENCIA	Dependência administrativa	Escola	`dim_escola.tp_rede_ensino`	Conversão para TINYINT; V07
TP_SITUACAO_FUNCIONAMENTO	Situação de funcionamento	Escola	– (análise das escolas sem matrícula)	nenhuma
CO_MUNICIPIO	Código IBGE do município	Escola	`dim_municipio.co_municipio`, `dim_escola.co_municipio`	Conversão para INT; V03
NO_MUNICIPIO	Nome do município	Escola	`dim_municipio.nome_municipio`	RT01, RT02, RT03; V04
SG_UF	Sigla da UF	Escola	`dim_municipio.uf`	RT04; V05, V06
CO_UF	Código IBGE da UF	Escola	– (referência)	nenhuma
QT_MAT_BAS	Matrículas na educação básica (total)	Matrícula	– (conferência)	V10: deve ser igual à soma das etapas
QT_MAT_INF_CRE … QT_MAT_EJA_MED (12 colunas)	Matrículas por etapa	Matrícula	`fact_matricula.qt_matricula`	Desdobramento em linhas e soma por etapa (RT05); V09; RT06

Em 2024 todas as colunas vêm do arquivo único `microdados_ed_basica_2024.csv`. `QT_MAT_PROF_TEC_IFTP_CT` e `QT_MAT_PROF_IFTP_QP` só existem a partir de 2025 e ficam nulas na carga de 2024.

2. Etapas de ensino (`dw.dim_etapa_ensino`)

As 8 etapas não se sobrepõem e, somadas, dão exatamente `QT_MAT_BAS` em todas as escolas de 2024 e 2025. Colunas que agregam outras foram excluídas para evitar dupla contagem: `QT_MAT_INF`, `QT_MAT_FUND`, `QT_MAT_PROF` e `QT_MAT_PROF_TEC`, esta última porque inclui o médio integrado, já contado em `QT_MAT_MED`.

tp_etapa_ensino	ds_etapa_ensino	Colunas de origem (somadas)	Matrículas 2024	Matrículas 2025
1	Educação Infantil - Creche	QT_MAT_INF_CRE	4.187.691	4.182.646
2	Educação Infantil - Pré-escola	QT_MAT_INF_PRE	5.304.203	5.103.536
3	Ensino Fundamental - Anos Iniciais	QT_MAT_FUND_AI	14.498.233	14.514.244
4	Ensino Fundamental - Anos Finais	QT_MAT_FUND_AF	11.504.123	11.292.523
5	Ensino Médio	QT_MAT_MED (inclui integrado e normal/magistério)	7.790.396	7.370.879
6	Educação Profissional (concomitante, subsequente e FIC)	QT_MAT_PROF_TEC_CONC + QT_MAT_PROF_TEC_SUBS + QT_MAT_PROF_FIC_CONC + QT_MAT_PROF_TEC_IFTP_CT[1] + QT_MAT_PROF_IFTP_QP[1]	1.412.957	1.302.483
7	EJA - Ensino Fundamental	QT_MAT_EJA_FUND	1.414.929	1.406.442
8	EJA - Ensino Médio	QT_MAT_EJA_MED	976.390	845.627
-1	Não se aplica (escola sem matrícula)	– (membro técnico da RT06, nunca chega à fato)	–	–
	Total = soma de QT_MAT_BAS		**47.088.922**	**46.018.380**

[1] Colunas criadas pelo INEP em 2025; não existem no arquivo de 2024.

3. Esquema staging

staging.censo_escolar

Recebe os CSVs com uma linha por escola e por ano de referência. As colunas de dados são `VARCHAR` para que a carga nunca falhe por tipo; a conversão e a validação são feitas pelas functions e pelo trigger de validação.

Coluna	Tipo	Nulo	Descrição
id_staging	BIGINT IDENTITY	não	Chave primária; referenciada por `dw.log_inconsistencia`
nu_ano_referencia	INT	não	Ano da carga, informado ao pipeline
no_arquivo_origem	VARCHAR(400)	não	Caminho do(s) CSV(s) de origem
dt_carga_staging	DATETIME2(0)	não	Data e hora da carga (padrão `SYSDATETIME()`)
nu_ano_censo	VARCHAR(10)	sim	NU_ANO_CENSO
sg_uf	VARCHAR(10)	sim	SG_UF
co_uf	VARCHAR(10)	sim	CO_UF
no_municipio	VARCHAR(200)	sim	NO_MUNICIPIO
co_municipio	VARCHAR(20)	sim	CO_MUNICIPIO
no_entidade	VARCHAR(400)	sim	NO_ENTIDADE
co_entidade	VARCHAR(20)	sim	CO_ENTIDADE
tp_dependencia	VARCHAR(10)	sim	TP_DEPENDENCIA
tp_situacao_funcionamento	VARCHAR(10)	sim	TP_SITUACAO_FUNCIONAMENTO
qt_mat_bas	VARCHAR(20)	sim	QT_MAT_BAS
qt_mat_inf_cre, qt_mat_inf_pre, qt_mat_fund_ai, qt_mat_fund_af, qt_mat_med	VARCHAR(20)	sim	Colunas QT_MAT_* de mesmo nome
qt_mat_prof_tec_conc, qt_mat_prof_tec_subs, qt_mat_prof_fic_conc	VARCHAR(20)	sim	Colunas QT_MAT_* de mesmo nome
qt_mat_prof_tec_iftp_ct, qt_mat_prof_iftp_qp	VARCHAR(20)	sim	Colunas QT_MAT_* de mesmo nome; nulas em 2024
qt_mat_eja_fund, qt_mat_eja_med	VARCHAR(20)	sim	Colunas QT_MAT_* de mesmo nome

Índice: `ix_censo_escolar_ano` (nu_ano_referencia) INCLUDE (co_entidade, co_municipio). Triggers: `trg_censo_escolar_auditoria` e `trg_censo_escolar_validacao`. View: `staging.vw_censo_escolar_valido` (linhas sem inconsistência ERRO).

staging.arquivo_fonte

Configuração da ingestão: uma linha por ano de referência.

Coluna	Tipo	Nulo	Descrição
nu_ano_referencia	INT	não	Chave primária
tp_layout	VARCHAR(10)	não	`UNICO` (cadastro e matrículas no mesmo CSV) ou `SEPARADO`
ds_caminho_escola	VARCHAR(400)	não	CSV de cadastro (no layout UNICO, também traz as matrículas)
ds_formato_escola	VARCHAR(400)	não	Arquivo de formato XML do CSV acima
ds_caminho_matricula	VARCHAR(400)	sim	CSV de matrículas; obrigatório no layout SEPARADO
ds_formato_matricula	VARCHAR(400)	sim	Arquivo de formato XML do CSV de matrículas

4. Dimensões (esquema dw)

dw.dim_escola – SCD tipo 2

Coluna	Tipo	Nulo	Descrição	Origem / regra
sk_escola	INT IDENTITY	não	Surrogate key (PK)	gerada
co_entidade	BIGINT	não	Identificador natural INEP	CO_ENTIDADE
no_entidade	VARCHAR(200)	não	Nome padronizado	NO_ENTIDADE + RT01, RT02, RT03
co_municipio	INT	não	FK para `dim_municipio.co_municipio`	CO_MUNICIPIO
tp_rede_ensino	TINYINT	não	Rede de ensino (1 a 4, ver seção 7)	TP_DEPENDENCIA
dt_inicio	DATE	não	Início da validade: 01/01 do ano em que a versão surgiu	pipeline

Coluna	Tipo	Nulo	Descrição	Origem / regra
dt_fim	DATE	sim	Fim da validade: 31/12 do ano anterior à mudança; NULL = aberta	pipeline
fl_ativo	CHAR(1)	não	S = versão vigente; N = histórica ou escola fora do Censo	pipeline

Restrições: CHECK em `tp_rede_ensino` (1–4), `fl_ativo` (S/N) e `dt_fim >= dt_inicio`; índice único (`co_entidade` , `dt_inicio`); índice único filtrado (`co_entidade`) WHERE `fl_ativo = 'S'` . Atributos versionados: `no_entidade` , `co_municipio` , `tp_rede_ensino` .

dw.dim_municipio – SCD tipo 1

Coluna	Tipo	Nulo	Descrição	Origem / regra
sk_municipio	INT IDENTITY	não	Surrogate key (PK)	gerada
co_municipio	INT	não	Código IBGE, 7 dígitos (único)	CO_MUNICIPIO
uf	CHAR(2)	não	Unidade federativa (CHECK nas 27 siglas)	SG_UF + RT04
nome_municipio	VARCHAR(200)	não	Nome padronizado	NO_MUNICIPIO + RT01, RT02, RT03

Se um registro vier sem nome ou UF, o valor é obtido das outras escolas do mesmo código IBGE.

dw.dim_tempo

Coluna	Tipo	Nulo	Descrição
sk_tempo	INT	não	PK no formato AAAAMMDD (`dw.fn_sk_tempo`)
ano	INT	não	Ano
mes	TINYINT	não	Mês (1–12)
dia	TINYINT	não	Dia (1–31)
dt_calendario	DATE	não	Data (única)

Uma linha por dia de cada ano carregado. A fato usa a data de referência do Censo (última quarta-feira de maio): 20240529 e 20250528.

dw.dim_etapa_ensino

Coluna	Tipo	Nulo	Descrição
sk_etapa_ensino	INT IDENTITY	não	Surrogate key (PK); -1 = membro "Não se aplica"
tp_etapa_ensino	INT	não	Código da etapa, único (ver seção 2)
ds_etapa_ensino	VARCHAR(200)	não	Descrição da etapa

5. Fato (esquema dw)

dw.fact_matricula

Grão: ano (data de referência) × escola × etapa de ensino. Só há linha para etapas com matrícula: 411.643 linhas em 2024 e 409.480 em 2025.

Coluna	Tipo	Nulo	Descrição	Origem / regra
sk_tempo	INT	não	FK para `dim_tempo` (data de referência do Censo)	`dw.fn_data_referencia_censo`
sk_escola	INT	não	FK para `dim_escola`, versão vigente na data de referência	CO_ENTIDADE
sk_municipio	INT	não	FK para `dim_municipio`	CO_MUNICIPIO
sk_etapa_ensino	INT	não	FK para `dim_etapa_ensino`	coluna QT_MAT_* de origem
qt_matricula	INT	não	Número de matrículas; CHECK > 0	soma das colunas da etapa (RT05); ⩽ 0 vai para o log (RT06)
dt_carga	DATETIME2(0)	não	Data e hora da carga	`SYSDATETIME()`

PK: (`sk_tempo` , `sk_escola` , `sk_etapa_ensino`). Índices: `ix_fact_matricula_municipio` e `ix_fact_matricula_etapa` , ambos com INCLUDE (`qt_matricula`). Trigger: `trg_fact_matricula_rt06` (INSTEAD OF INSERT).

View analítica `dw.vw_matricula`: junta a fato com as quatro dimensões e acrescenta `ds_rede_ensino` (Federal, Estadual, Municipal, Privada).

6. Tabelas de controle (esquema dw)

dw.auditoria

Uma linha por carga na staging, gravada pelo trigger `trg_censo_escolar_auditoria` (item 7 do enunciado).

Coluna	Tipo	Nulo	Descrição
id_auditoria	INT IDENTITY	não	PK
no_usuario	NVARCHAR(128)	não	Usuário que fez a carga (`SUSER_SNAME()`)
dt_carga	DATETIME2(0)	não	Data e hora da carga
nu_ano_referencia	INT	não	Ano de referência dos dados
qt_registros	INT	não	Quantidade de registros carregados
no_tabela_destino	VARCHAR(128)	não	Tabela carregada (`staging.censo_escolar`)
no_arquivo_origem	VARCHAR(400)	sim	CSV(s) de origem
id_execucao	UNIQUEIDENTIFIER	sim	Execução do pipeline; nulo em cargas manuais

dw.log_inconsistencia

Dados inválidos e inconsistências registrados pelos triggers (RF08, RT06).

Coluna	Tipo	Nulo	Descrição
id_log	BIGINT IDENTITY	não	PK
dt_registro	DATETIME2(0)	não	Data e hora do registro
nu_ano_referencia	INT	sim	Ano de referência
no_objeto_origem	VARCHAR(128)	não	Trigger que registrou
cd_regra	VARCHAR(10)	não	V01 a V10 ou RT06

Coluna	Tipo	Nulo	Descrição
tp_severidade	VARCHAR(10)	não	ERRO ou ALERTA
id_staging	BIGINT	sim	Linha da staging (regras V)
co_entidade	VARCHAR(20)	sim	Código da escola
no_campo	VARCHAR(60)	sim	Campo avaliado
vl_campo	VARCHAR(400)	sim	Valor recebido
ds_inconsistencia	VARCHAR(400)	não	Descrição
id_execucao	UNIQUEIDENTIFIER	sim	Execução do pipeline

dw.log_execucao

Monitoramento: uma linha por etapa de cada execução, gravada por `dw.usp_executar_etapa`.

Coluna	Tipo	Nulo	Descrição
id_log_execucao	INT IDENTITY	não	PK
id_execucao	UNIQUEIDENTIFIER	não	Execução do pipeline
nu_ano_referencia	INT	não	Ano processado
no_etapa	VARCHAR(100)	não	Nome da etapa (0 a 6)
no_procedure	VARCHAR(128)	não	Procedure executada
dt_inicio	DATETIME2(3)	não	Início
dt_fim	DATETIME2(3)	sim	Fim
qt_linhas	INT	sim	Linhas afetadas pela etapa
ds_status	VARCHAR(10)	não	EXECUTANDO, SUCESSO ou ERRO
ds_mensagem	NVARCHAR(2000)	sim	Erro: número, procedure, linha e mensagem
no_usuario	NVARCHAR(128)	não	Usuário (`SUSER_SNAME()`)

7. Domínios de códigos

Campo	Código	Significado
tp_rede_ensino / TP_DEPENDENCIA	1	Federal
tp_rede_ensino / TP_DEPENDENCIA	2	Estadual
tp_rede_ensino / TP_DEPENDENCIA	3	Municipal
tp_rede_ensino / TP_DEPENDENCIA	4	Privada
TP_SITUACAO_FUNCIONAMENTO	1	Em atividade
TP_SITUACAO_FUNCIONAMENTO	2	Paralisada
TP_SITUACAO_FUNCIONAMENTO	3	Extinta (no ano do Censo)
fl_ativo	S / N	Versão vigente / versão histórica ou escola fora do Censo
tp_severidade	ERRO	Registro retirado do DW
tp_severidade	ALERTA	Registro carregado com correção, ou só sinalizado
ds_status	EXECUTANDO / SUCESSO / ERRO	Situação de uma etapa em `dw.log_execucao`
tp_layout	UNICO / SEPARADO	Formato dos arquivos do ano em `staging.arquivo_fonte`

As regras V01 a V10 e RT01 a RT06 citadas neste dicionário estão descritas no documento de arquitetura.