Documento de Arquitetura – ETL e Data Warehouse do Censo Escolar

Oct 20, 2026 · @lalmo

1. Visão geral

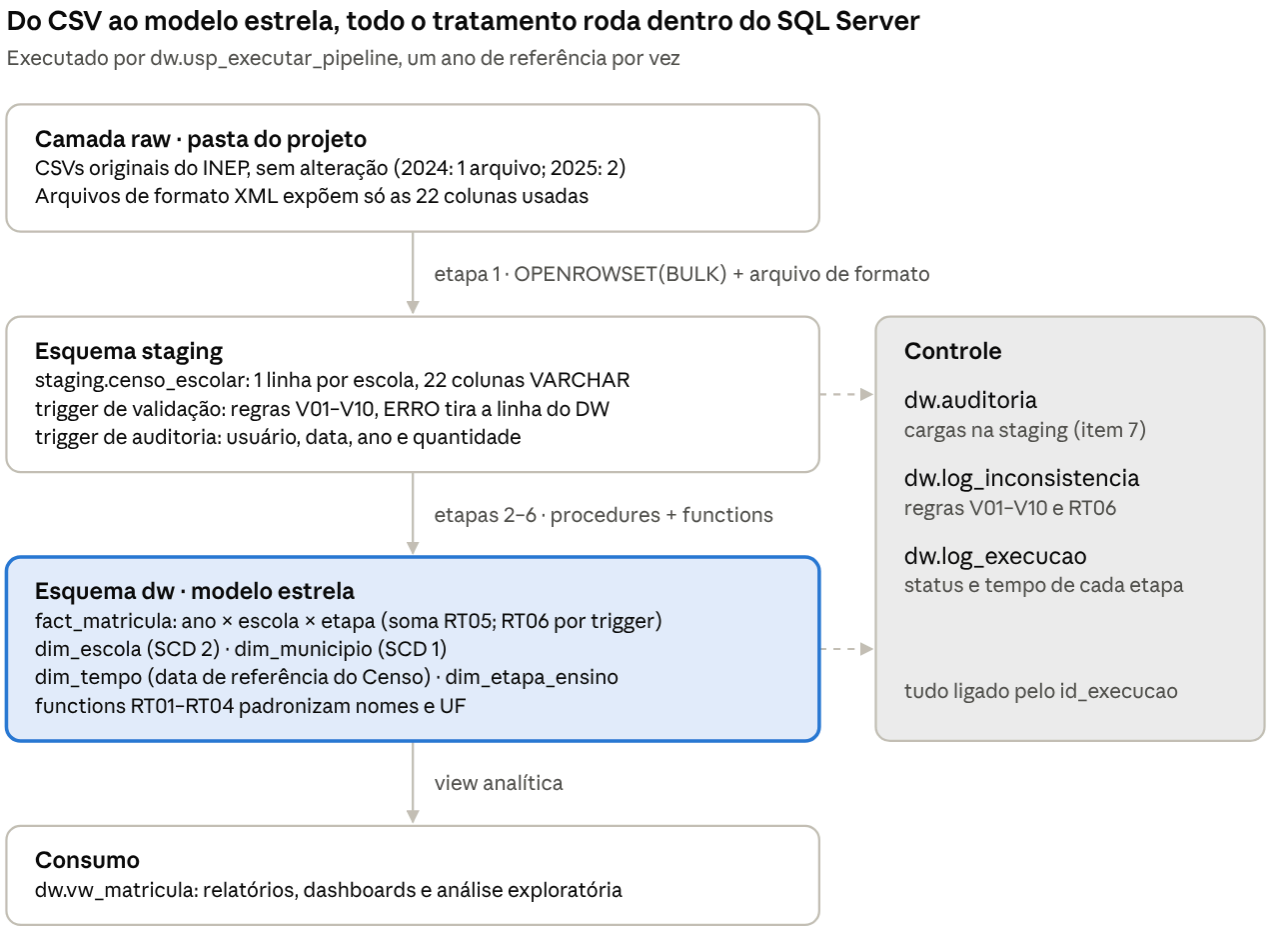
O pipeline carrega os microdados do Censo Escolar 2024 e 2025 (INEP) num Data Warehouse estrela no SQL Server, usando apenas stored procedures, functions e triggers. A carga dos dois anos foi validada: 16 de 16 indicadores conferem com valores calculados de forma independente a partir dos CSVs, e o total do DW é igual ao total oficial de matrículas do INEP (`QT_MAT_BAS`) em 100% das escolas.

Item	Descrição
Projeto	ETL e Data Warehouse para Dados Públicos da Educação Básica
Fonte	Microdados do Censo Escolar da Educação Básica – INEP, anos 2024 e 2025
Banco	`db_educacional` , esquemas `staging` e `dw` (RF02)
Tecnologias	SQL Server 2019 em container Docker, T-SQL (procedures, functions, triggers, views), `OPENROWSET(BULK)` com arquivo de formato XML
Volume	215.545 escolas (2024) e 214.192 escolas (2025); 821.123 linhas na fato; 93,1 milhões de matrículas
Execução	`EXEC dw.usp_executar_pipeline @nu_ano_referencia = <ano>` , uma vez por ano, do mais antigo para o mais recente

Os arquivos do Censo foram baixados do portal gov.br/INEP e ficam, sem alteração, na pasta do projeto, que é a camada raw. O download é a única etapa fora do banco: a partir do CSV, todo o tratamento é feito por objetos do SQL Server, como pede a versão atualizada do enunciado.

2. Arquitetura

O dado passa por quatro camadas: o CSV original (raw), a staging, o DW estrela e a view de consumo. As tabelas de controle registram cada passo.



arquitetura do pipeline · 4 camadas + controle

A staging recebe o CSV como texto e o valida. O DW só recebe registros válidos, já padronizados pelas functions. A auditoria e os logs ficam no esquema `dw` e são preenchidos por triggers e pela procedure que executa as etapas.

3. Fonte de dados

O INEP mudou o formato dos microdados entre 2024 e 2025, então o pipeline aceita dois layouts e grava ambos na mesma tabela de staging. Desde 2021, por causa da LGPD, os arquivos têm uma linha por escola, com as matrículas já contadas por etapa em colunas (`QT_MAT_*`). Não há mais uma linha por aluno.

Ano	Layout	Arquivo(s) usado(s)	Linhas	Campos
2025	SEPARADO	`Tabela_Escola_2025_V2.csv` (cadastro)	214.192	290

Ano	Layout	Arquivo(s) usado(s)	Linhas	Campos
2025	SEPARADO	`Tabela_Matricula_2025_V2.csv` (matrículas)	178.766	263
2024	UNICO	`microdados_ed_basica_2024.csv` (cadastro e matrículas)	215.545	426

Características comuns, verificadas em todas as linhas antes da carga:

- **Codificação** ISO-8859-1 (Latin-1), separador `;`, sem aspas, quebra de linha LF.
- **Estrutura estável:** todas as linhas têm o mesmo número de campos do cabeçalho, e nenhum código de escola se repete.
- **Escolas sem matrícula:** em 2024 elas vêm com as colunas `QT_MAT_*` vazias. Em 2025 elas simplesmente não aparecem no arquivo de matrículas, por isso a staging junta o cadastro com as matrículas por LEFT JOIN.
- **Etapa não ofertada:** é informada como `0`, não como vazio.

A tabela `staging.arquivo_fonte` guarda, para cada ano, o layout, o caminho de cada CSV e o arquivo de formato XML correspondente. Para incluir um novo ano, basta cadastrar uma linha nela e gerar o arquivo de formato com `staging.usp_gerar_arquivo_formato`, que lê o cabeçalho do próprio CSV.

4. Modelo dimensional

O DW segue o modelo estrela do item 5 do enunciado. O grão da fato é **ano × escola × etapa de ensino**, e cada linha guarda a quantidade de matrículas daquela etapa naquela escola.

Tabela	Tipo	Chave	Histórico	Linhas após 2024 + 2025
`dw.fact_matricula`	Fato	PK (`sk_tempo`, `sk_escola`, `sk_etapa_ensino`)	substituída por ano	821.123
`dw.dim_escola`	Dimensão	`sk_escola` (IDENTITY)	SCD tipo 2	229.100 (214.192 vigentes)
`dw.dim_municipio`	Dimensão	`sk_municipio` (IDENTITY), `co_municipio` único	SCD tipo 1	5.571

Tabela	Tipo	Chave	Histórico	Linhas após 2024 + 2025
`dw.dim_tempo`	Dimensão	`sk_tempo` = AAAAMMDD	calendário fixo	731 (todos os dias de 2024 e 2025)
`dw.dim_etapa_ensino`	Dimensão	`sk_etapa_ensino` (IDENTITY)	carga fixa	9 (8 etapas + membro -1)

Etapas de ensino. Os microdados não têm uma coluna de etapa; as etapas são colunas. Foram escolhidas as 8 colunas que não se sobrepõem e cuja soma é igual a `QT_MAT_BAS` em 100% das escolas dos dois anos. A combinação foi encontrada testando as alternativas contra os dados. O detalhe de cada etapa está no dicionário de dados.

Tempo. O Censo é anual, mas a `dim_tempo` pede ano, mês e dia. A fato aponta para a data de referência oficial do Censo, a última quarta-feira de maio (Dia Nacional do Censo Escolar): 29/05/2024 e 28/05/2025. A dimensão recebe todos os dias do ano, o que permite cruzar com outras fontes diárias no futuro.

Escola (SCD 2). São versionados o nome, o município e a rede de ensino. Uma versão vale de `dt_inicio` (01/01 do ano em que surgiu) até `dt_fim` (31/12 do ano anterior à mudança). `fl_ativo = 'S'` marca a versão vigente, e um índice único filtrado garante no máximo uma por escola. A fato de cada ano liga-se à versão vigente na data de referência daquele ano, então 2024 continua mostrando o nome antigo e 2025 o novo.

Município (SCD 1). Uma correção de nome ou UF sobrescreve o valor anterior. Por exigência do enunciado, a `dim_escola` guarda `co_municipio`, com chave estrangeira para `dim_municipio.co_municipio`, e a fato guarda `sk_municipio`. A redundância é intencional: serve de atalho analítico, sem precisar passar pela escola.

Membro -1. `sk_etapa_ensino = -1` ("Não se aplica") representa escolas sem nenhuma matrícula. Ele só aparece no fluxo da RT06 e nunca chega à fato.

5. Pipeline

Uma chamada de `dw.usp_executar_pipeline` processa um ano inteiro em 7 etapas. Cada etapa é uma procedure com a mesma assinatura (`@nu_ano_referencia` , `@qt_linhas OUTPUT`), executada e registrada por `dw.usp_executar_etapa` .

0. `dw.usp_validar_ordem_carga` recusa um ano anterior ao último já carregado e um ano sem arquivo configurado.

1. `staging.usp_carregar_staging` apaga a staging do ano e lê o CSV com `OPENROWSET(BULK)` e o arquivo de formato, num único `INSERT ... SELECT`. Os triggers de auditoria e validação disparam uma vez, sobre o lote inteiro.
2. `dw.usp_carregar_dim_tempo` insere os dias do ano que ainda não existem.
3. `dw.usp_carregar_dim_etapa_ensino` mantém as 8 etapas e o membro -1 com `MERGE`.
4. `dw.usp_carregar_dim_municipio` padroniza nome e UF de cerca de 5.600 valores distintos e aplica o SCD 1 com `MERGE`.
5. `dw.usp_carregar_dim_escola` padroniza os nomes, fecha as versões alteradas ou ausentes e abre as novas (SCD 2).
6. `dw.usp_carregar_fact_matricula` desdobra as colunas em etapas, soma (RT05) e insere. O trigger `INSTEAD OF` aplica a RT06.

Objeto	Tipo	Papel
`dw.usp_executar_pipeline`	Procedure	Orquestra as etapas e grava o id da execução em `SESSION_CONTEXT`
`dw.usp_executar_etapa`	Procedure	Registra início, fim, linhas, status e erro em `dw.log_execucao`
`staging.usp_gerar_arquivo_formato`	Procedure	Gera o XML de formato a partir do cabeçalho de um CSV novo
`dw.fn_remover_acentos`, `fn_limpar_espacos`, `fn_capitalizar`, `fn_padronizar_nome`	Functions escalares	RT01, RT02, RT03
`dw.fn_uf_valida`, `fn_uf_por_codigo_ibge`, `fn_padronizar_uf`	Functions escalares	RT04
`dw.fn_converter_inteiro`, `fn_data_referencia_censo`, `fn_sk_tempo`	Functions escalares	Conversão de tipos e datas
`dw.fn_desdobrar_etapas`	Function de tabela (inline)	Transforma as 12 colunas `QT_MAT_*` em linhas por etapa
`staging.trg_censo_escolar_auditoria`	Trigger AFTER INSERT	Auditoria das cargas (item 7)

Objeto	Tipo	Papel
`staging.trg_censo_escolar_validacao`	Trigger AFTER INSERT	Regras V01–V10 (RF08)
`dw.trg_fact_matricula_rt06`	Trigger INSTEAD OF INSERT	RT06
`staging.vw_censo_escolar_valido`	View	Staging sem os registros marcados como ERRO
`dw.vw_matricula`	View	Fato com as dimensões, pronta para relatórios

Requisito	Atendimento
RF01 – download anual	Arquivos baixados do portal do INEP e guardados sem alteração na camada raw. O enunciado atualizado tornou o download opcional.
RF02 – banco e esquemas	Script 01: `db_educacional` com `staging` e `dw`
RF03 – tabela de staging	`staging.censo_escolar`: 22 colunas de dados, entre 263 e 426 do CSV
RF04 – modelo dimensional	Script 03: 4 dimensões e a fato, com chaves, FKs e CHECKs
RF05 – pipeline	Etapas 1 a 6 acima, idempotentes
RF06 – objetos do SQL Server	10 procedures, 11 functions, 3 triggers, 2 views; nenhum código externo
RF07 – functions de padronização	RT01–RT04 e a transformação das etapas, em functions
RF08 – triggers de inconsistência	Dois triggers gravam em `dw.log_inconsistencia`

6. Regras de transformação e validação

As regras de negócio ficam no banco: as de transformação em functions, as de qualidade em triggers. Nomes de escolas e municípios passam por RT02, RT01 e RT03, nessa ordem: `' ESCOLA ESTADUAL JOÃO DE DEUS '` vira `'Escola Estadual Joao de Deus'`.

Regra	Implementação	Detalhe
RT01 – remover acentos	`dw.fn_remover_acentos`	`TRANSLATE` com collation binária, para que "A" não case com "á" e vire minúsculo
RT02 – TRIM	`dw.fn_limpar_espacos`	Também troca tabulação, quebra de linha e espaço não separável por espaço e elimina espaços duplicados. Texto vazio vira NULL.
RT03 – capitalização	`dw.fn_capitalizar`	Maiúscula após espaço, hífen e apóstrofo ("Alta Floresta D'Oeste", "Villa-Lobos"); de/da/do/das/dos/e em minúsculas; romanos I a XX em maiúsculas
RT04 – UF válida	`dw.fn_padronizar_uf`	TRIM e maiúsculas. Se a sigla continuar inválida, deriva a UF dos 2 primeiros dígitos do código IBGE do município.
RT05 – soma por ano/escola/município/etapa	`dw.fn_desdobrar_etapas` + `GROUP BY`	A etapa Educação Profissional soma 3 colunas em 2024 e 5 em 2025
RT06 – qt_matricula ⩽ 0 vai para o log	`dw.trg_fact_matricula_rt06` (INSTEAD OF)	Vale para qualquer INSERT na fato, não só para o do pipeline

Interpretação da RT06. Os microdados trazem `0` em toda etapa que a escola não oferece. Aplicar a regra a cada zero geraria cerca de 1 milhão de linhas de log por ano, sem informação útil. Por isso, uma etapa com zero significa etapa não ofertada e não gera

registro. A escola sem nenhuma matrícula gera um registro na etapa -1 com quantidade 0, que o trigger desvia para o log: foram 36.259 escolas em 2024 e 35.426 em 2025, a maioria paralisada ou extinta. Valores negativos também seriam desviados, mas não ocorreram.

O trigger de validação da staging aplica 10 regras. ERRO tira o registro do DW (pela view `staging.vw_censo_escolar_valido`). ALERTA mantém o registro, com a correção aplicada pelas functions.

Código	Severidade	Verificação
V01	ERRO	Código da escola ausente ou não numérico
V02	ERRO	Nome da escola vazio
V03	ERRO	Código IBGE do município ausente, com tamanho diferente de 7 ou de UF inexistente
V04	ALERTA	Nome do município vazio; o nome é obtido de outra escola do mesmo código
V05	ALERTA	UF inválida; corrigida pelo código IBGE (RT04)
V06	ALERTA	UF válida, mas diferente da UF do código IBGE
V07	ERRO	Rede de ensino fora de 1 a 4
V08	ERRO	Ano do arquivo diferente do ano da carga
V09	ERRO	Quantidade de matrícula não numérica ou negativa
V10	ALERTA	`QT_MAT_BAS` diferente da soma das 8 etapas

Nos dados reais, só uma escola de 2025 (código 43145833) gerou alertas: veio sem UF e sem nome de município (V04 e V05). Ela foi carregada como RS, com o município obtido das outras escolas do código 4319901. Nenhum ERRO ocorreu nos dois anos. Todas as regras foram exercitadas com registros de teste no script 08.

7. Auditoria, monitoramento e idempotência

Cada execução do pipeline recebe um `id_execucao` (GUID), gravado em `SESSION_CONTEXT`. Os triggers leem esse valor, então a auditoria, o log de etapas e as inconsistências de uma mesma execução ficam ligados entre si.

Tabela	Preenchida por	Conteúdo
`dw.auditoria`	Trigger AFTER INSERT na staging	Usuário (`SUSER_SNAME()`), data, ano de referência, quantidade de registros, arquivo de origem e id da execução. Uma linha por carga (item 7).
`dw.log_execucao`	`dw.usp_executar_etapa`	Uma linha por etapa: início, fim, linhas afetadas, status (`EXECUTANDO` , `SUCESSO` , `ERRO`) e mensagem de erro com número, procedure e linha
`dw.log_inconsistencia`	Triggers de validação e RT06	Regra, severidade, registro de origem (`id_staging` e código da escola), campo, valor recebido e descrição

Como a auditoria está num trigger, até uma inserção manual na staging fica registrada. Os registros de teste do script 08 aparecem nela com o ano 1900.

Transações. Cada etapa é uma transação com `XACT_ABORT ON` . Se uma etapa falha, só ela é desfeita, e o registro de erro é gravado depois do rollback, para não se perder. As etapas anteriores ficam gravadas, e basta executar o pipeline de novo.

Idempotência. Reexecutar um ano produz o mesmo resultado:

- a staging e a fato do ano são apagadas e recarregadas;
- `dim_tempo` e `dim_etapa_ensino` só recebem o que falta;
- `dim_municipio` usa `MERGE` ;
- na `dim_escola` , o reprocessamento do último ano primeiro desfaz as versões abertas e fechadas por aquele ano e depois as refaz.

O script 08 reprocessa 2025 e confirma que as contagens da fato e das dimensões não mudam.

Ordem de carga. Os anos devem ser carregados do mais antigo para o mais recente, porque o histórico SCD 2 depende disso. A etapa 0 recusa um ano anterior ao último carregado com o erro 50020, antes de qualquer alteração, e o script 08 testa essa recusa. Reprocessar o próprio último ano é permitido.

8. Resultados, decisões e limitações

A carga de 2024 e 2025 passou nas 16 conferências do script 08. Os valores esperados foram calculados por um processo independente, em Python, lendo os mesmos CSVs.

Indicador	2024	2025
Registros na staging	215.545	214.192
Linhas na fato	411.643	409.480
Total de matrículas (= soma de `QT_MAT_BAS`)	47.088.922	46.018.380
Escolas sem matrícula enviadas ao log (RT06)	36.259	35.426
Escolas que mudaram de nome, município ou rede (SCD 2)	–	8.572
Escolas novas	–	4.983
Escolas que deixaram de constar (versão fechada)	–	6.336
Inconsistências ERRO / ALERTA	0 / 0	0 / 2

Decisão	Motivo
Ler o CSV com `OPENROWSET(BULK)` e arquivo de formato XML, num único `INSERT ... SELECT`	Permite trazer só as 22 colunas necessárias (RF03) e faz os triggers dispararem sobre o lote. O `BULK INSERT` não dispara triggers sem `FIRE_TRIGGERS` e não pula colunas sem arquivo de formato.
`CODEPAGE = 'RAW'` e banco em `Latin1_General_CI_AS`	No Linux, o SQL Server 2019 só aceita `RAW`. Os bytes Latin-1 do INEP são lidos corretamente pela página de código 1252 do banco.
Staging toda em `VARCHAR`	A carga nunca falha por tipo; a validação e a conversão ficam nas regras do banco
Validação em trigger, sem rejeitar a linha	O registro inválido fica na staging para investigação, e a view de válidos o exclui do DW
Funções aplicadas a valores distintos	Na `dim_municipio`, a padronização roda cerca de 5.600 vezes em vez de 215 mil

Decisão	Motivo
Etapas em transações separadas	Uma falha não apaga o log da execução, e o reprocessamento é seguro

Limitações conhecidas

- A capitalização não reconhece siglas: "EMEF" vira "Emef", e "E M E I E F" vira "E M e I e F".
- Cada ano novo precisa do seu arquivo de formato, porque o INEP muda colunas de um ano para outro. O utilitário `staging.usp_gerar_arquivo_formato` gera esse arquivo a partir do cabeçalho do CSV.
- O download dos microdados não é automatizado: o SQL Server não acessa a internet sem `xp_cmdshell`, que foi evitado por segurança.
- Os anos precisam ser carregados em ordem cronológica. Para inserir um ano antigo depois, é preciso recarregar desde esse ano.